



Q-LEARNING



Aprender o valor das ações



O Q-Learning é um método de Aprendizagem por Reforço que aprende o **valor (utilidade)** de **cada ação** em **cada estado**, para tomar melhores decisões ao longo do tempo.



COMO FUNCIONA

1



O agente está num **estado** (s)

2



Escolhe uma **ação** (a) e executa-a.

3



Recebe uma **recompensa** (r) e observa o novo **estado** (s').

4



Atualiza o valor **Q(s, a)** com base na experiência.

5



Repete o processo até aprender boas **políticas**.

TABELA Q

Guarda o valor esperado de cada ação em cada estado.

Estados	Ações				
	Norte ↑	Sul ↓	Este →	Oeste ←	Esperar ⌛
S ₁	0,7	-0,2	0,4	0,1	0,0
S ₂	0,1	0,5	0,2	-0,1	0,0
S ₃	-0,3	0,2	0,6	0,2	0,0
S ₄	0,0	-0,1	0,3	0,7	0,0

Atualização do Q-Learning:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

α taxa de aprendizagem ($0 < \alpha \leq 1$)

γ fator de desconto ($0 \leq \gamma < 1$)

r recompensa recebida

s' novo estado

$\max_{a'} Q(s', a')$ melhor valor futuro

EXEMPLO MARÍTIMO

Um navio precisa navegar numa grelha para chegar ao porto (⚓) evitando rochas (⚓).

Estados	S ₄				
	S ₃				
	S ₂				
	S ₁				
		C ₁	C ₂	C ₃	C ₄
Columnas					



Início (navio)



Objetivo (porto)



Obstáculo (rocha)

Um passo do Q-Learning:



Com muitas experiências, o navio aprende a escolher as ações que o levam ao porto com o **maior valor esperado**.

VANTAGENS



Aprende com tentativa e erro.



Não precisa de um modelo do ambiente.



Funciona em ambientes incertos e dinâmicos.



Equilibra exploração e exploração.



EM RESUMO


O Q-Learning aprende os **melhores valores** das **ações** em cada **estado** e usa esse conhecimento para tomar **decisões** cada vez melhores.





RECUPERAR A EXPERIÊNCIA DO AGENTE

O agente recorda experiências passadas para aprender de forma mais eficiente.



IDEIA-CHAVE: Relembrar experiências passadas ajuda o agente a aprender mais rápido, evitar erros e tomar melhores decisões.



COMO GUARDAR AQUILO QUE O AGENTE APRENDEU?

A cada interação, o agente regista o que descobriu para usar no futuro.



1 INTERAÇÃO

O agente faz uma pergunta ou toma uma ação.



Exemplo:
Pergunta sobre regras de navegação.

2 OBSERVAÇÃO

O agente recebe informação do ambiente.



Exemplo:
Observa que a boia verde está a bombordo.

3 APRENDIZAGEM

O agente extrai um novo facto ou padrão.



Exemplo:
Aprende a associação entre boia verde e bombordo.

4 REGISTO

O agente guarda o que aprendeu na sua base de conhecimento.



Exemplo:
Guarda o novo facto com nível de confiança.

5 USO FUTURO

O agente usa o conhecimento guardado em decisões futuras.



Exemplo:
Usa este conhecimento para responder mais rapidamente.

EM RESUMO:



Interage



Observa



Aprende



Regista



Usa no futuro



Assim, o agente melhora a cada experiência!



$Q(s,a)$: VALOR DE UMA AÇÃO NUM ESTADO

$Q(s,a)$ indica a qualidade esperada de executar a ação a quando estamos no estado s .



1. O QUE É CADA COISA?



ESTADO (s)

Representa a situação atual do agente no ambiente.

Ex.: posição do barco no mar, condições do vento, etc.



AÇÃO (a)

É uma escolha que o agente pode fazer a partir do estado.

Ex.: navegar para Norte, Sul, Este ou Oeste.



$Q(s,a)$

É o valor esperado (a qualidade) de executar a ação a quando estamos no estado s .

Quanto maior o $Q(s,a)$, melhor esperamos que seja essa ação naquele estado.

2. EXEMPLO NO MAR

O barco está na posição destacada (estado s).
Que ação escolher?



Perigo alto



Perigo médio



Recompensa média



Recompensa alta

3. O QUE SIGNIFICA $Q(s,a)$?



$Q(s,a)$ é a **recompensa total esperada** no futuro ao executar a ação a a partir do estado s e, depois, seguir uma **política ótima**.

4. COMO É CALCULADO (IDEIA GERAL)

$$Q(s, a) = \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} Q(s', a') \mid s, a \right]$$



R_{t+1}

recompensa imediata obtida após executar a ação a .



γ

fator de desconto (0 a 1): dá menos peso a recompensas mais distantes no tempo.



$\max_{a'} Q(s', a')$

melhor valor futuro possível no novo estado s' que podemos alcançar.



$\mathbb{E}[\cdot \mid s, a]$

esperança matemática: média de todos os resultados possíveis ao executar a ação a no estado s (o mar é incerto!).

5. PARA QUE SERVE?



Comparando os valores $Q(s,a)$ de todas as ações disponíveis num estado s , o agente escolhe a ação com maior valor esperado, aumentando as hipóteses de alcançar boas recompensas e evitar perigos.



NORTE
 $Q = 4.2$



ESTE
 $Q = 6.8$



SUL
 $Q = 1.5$




OESTE
 $Q = -2.1$



ESCOLHER: ESTE
(maior Q esperado)



IDEIA-CHAVE: $Q(s,a)$ guia o agente a tomar boas decisões hoje para ter bons resultados amanhã.





A TABELA Q GUARDA OS VALORES

Linhas = estados possíveis • Colunas = ações (combinações) • Valores = Verdadeiro (V) ou Falso (F)

ESTADOS POSSÍVEIS DAS PROPOSIÇÕES

Com duas proposições (P e Q), existem 4 estados possíveis.



V = Verdadeiro
F = Falso

	PROPOSIÇÕES		AÇÕES (COMBINAÇÕES LÓGICAS)					
	P	Q	NÃO P (¬P) 	NÃO Q (¬Q) 	E (P ∧ Q) 	OU (P ∨ Q) 	SE...ENTÃO (P → Q) 	SE E SOMENTE SE (P ↔ Q) 
1	V	V	F	F	V	V	V	V
2	V	F	F	V	F	V	F	F
3	F	V	V	F	F	V	V	F
4	F	F	V	V	F	F	V	V

LEGENDA DAS AÇÕES



NÃO P (¬P):
nega P



NÃO Q (¬Q):
nega Q



E (P ∧ Q):
P e Q
são verdadeiras



OU (P ∨ Q):
pelo menos
uma é verdadeira



SE...ENTÃO (P → Q):
se P é verdadeira,
então Q também



SE E SOMENTE SE (P ↔ Q):
P e Q têm o mesmo
valor de verdade



IDEIA-CHAVE

A Tabela Q organiza, de forma clara e completa, todos os valores de verdade das combinações lógicas.



DICA DE NAVEGAÇÃO

Leia cada linha como um estado do mar e cada coluna como uma ação que você pode tomar.





UM ESTADO NOVO COMEÇA SEM EXPERIÊNCIA

Dos factos às conclusões e decisões explicáveis



FATOS



Gás detetado

Q = 0



Ventilação
ativa

Q = 0



Pessoas
presentes

Q = 0



Comunicação
disponível

Q = 0

REGRAS

Base de conhecimento
(exemplos de regras)



G = 1 E V = 1 → PERIGO



P > 0 E G = 1 → PERIGO



V = 1 E P = 0 → VENTILAR



C = 1 E G = 0 → NORMAL



G = 0 E P = 0 → NORMAL

MOTOR DE INFERÊNCIA

Aplica as regras



Combina
factos e regras



Avalia as
condições



Tira
conclusões

QUESTÕES (Q)



Gás detetado

Q = 0



Ventilação
ativa

Q = 0



Pessoas
presentes

Q = 0



Comunicação
disponível

Q = 0

Total de questões Q = 0

DECISÃO INICIAL



Sem experiência prévia,
agir com cautela.

AÇÃO RECOMENDADA



**AVALIAR E
RECOLHER MAIS
INFORMAÇÃO**

Reduzir incerteza antes
de concluir.



Objetivo: Transformar factos em conclusões fiáveis, passo a passo.



Princípio: Medir a incerteza com questões e decidir com responsabilidade.





O AGENTE EXECUTA UMA AÇÃO



escolher ação no estado atual e mover.

1. ESTADO ATUAL



FACTOS VERDADEIROS

- ✓ G = à esquerda
- ✓ V = verdadeiro
- ✓ P = perigoso
- ✓ A = $\neg P$
- ✓ O = $\neg G$



2. AÇÕES POSSÍVEIS

- ↑ Ir para a esquerda
- Ir para a direita
- ! Ir em frente
- ↻ Derrapar / Esperar

- G** torna G verdadeiro
- V** torna V verdadeiro
- P** torna P verdadeiro (pode ser perigoso)
- O** mantém-se no estado

O agente avalia o estado atual e gera as ações disponíveis.

3. ESCOLHER AÇÃO E EXECUTAR



O agente escolhe a melhor ação.



Ação escolhida:
IR PARA A DIREITA (V)

Objetivo: tornar V verdadeiro.



O agente executa a ação e move-se para o novo estado.



Regras de atualização
(do motor de inferência):

- V** torna-se verdadeiro
- G** torna-se falso
- O** torna-se falso



A ação altera o estado: alguns factos tornam-se verdadeiros, outros tornam-se falsos.

4. NOVO ESTADO RESULTANTE



FACTOS VERDADEIROS

- ✓ G = à esquerda
- ✓ V = verdadeiro
- ✓ P = perigoso
- ✓ A = $\neg P$
- ✓ O = $\neg G$

- ✗
- ✓
- ✗
- ✓
- ✗



O QUE ACONTECEU?

- ✓ V tornou-se verdadeiro (o objetivo foi alcançado).
- ✗ G tornou-se falso (deixou de estar à esquerda).
- ✗ O tornou-se falso (deixou de se manter no estado).



O agente está agora num novo estado e o ciclo recomeça.



Agir, atualizar e repetir: o agente escolhe, executa, move-se e continua a procurar o objetivo.





O AMBIENTE DEVOLVE UMA RECOMPENSA

A conclusão é ajustada consoante a experiência obtida.



RECOMPENSA POSITIVA

O ambiente **confirma** a conclusão com uma evidência fiável.



- ✓ Fato observado
- ✓ Regra aplicada
- ✓ Conclusão confirmada
- ✓ Confiança aumenta



Recompensa: + pontos

A conclusão fica mais forte.



O agente aprende e melhora as próximas decisões.



PENALIZAÇÃO POR MOVIMENTO

O agente **não concluiu** ainda, continua a procurar evidências.



Ainda há dúvida



Novos factos são procurados



Consome tempo e recursos



Penalização: - pontos

Por cada ação que não conclui.



Incentiva decisões eficientes e bem fundamentadas.



PENALIZAÇÃO POR PERIGO

O ambiente devolve informação de **perigo** por uma conclusão incorreta ou tardia.



Conclusão errada ou tardia



Risco para a navegação



Consequências negativas



Penalização: -- pontos

Por erro ou por falta de ação.



Evita erros e promove segurança.



RESUMO DO CICLO DE RECOMPENSA



O ambiente **confirma** + pontos



O agente ainda procura - pontos



O ambiente sinaliza perigo -- pontos



A experiência ajusta a confiança e melhora decisões



O agente aprende com o ambiente e ajusta as suas conclusões para obter melhores resultados.





OBSERVAR O MELHOR VALOR FUTURO

Na lógica proposicional, escolhemos a conclusão que gera o maior benefício dentro das regras e dos factos observados.



1. FACTOS OBSERVADOS



	Vento moderado	✓
	Mar calmo	✓
	Boa visibilidade	✓
	Maré a favor	✓
	Combustível adequado	✓

2. REGRAS (IMPLICAÇÕES)

SE (Facto)	ENTÃO (Conclusão)
Vento moderado	Velocidade ótima →
Mar calmo	Risco baixo →
Boa visibilidade	Navegar direto →
Maré a favor	Chegada antecipada →
Combustível adequado	Maior autonomia →

3. CONCLUSÃO: ESCOLHER O MELHOR VALOR FUTURO

Avaliamos as conclusões possíveis e escolhemos a que produz o maior benefício futuro.

A

Rota Direta Rápida



- Chegada mais cedo
- Menor consumo
- Risco baixo

BENEFÍCIO: ALTO

B

Rota Costeira Segura



- Mais segura
- Mais tempo
- Consumo médio

BENEFÍCIO: MÉDIO

C

Rota Alternativa Longa



- Mais tempo
- Maior consumo
- Pouco vantajosa

BENEFÍCIO: BAIXO



Escolha: **ROTA DIRETA RÁPIDA (A)**
É a opção com o **MELHOR VALOR FUTURO**.



OBSERVAR

Recolhemos os factos relevantes do momento.



APLICAR REGRAS

Usamos as implicações lógicas para obter conclusões possíveis.



AVALIAR

Comparamos os resultados e o impacto futuro de cada opção.



ESCOLHER O MELHOR

Selecionamos a conclusão que traz o maior benefício dentro das regras.



Na lógica proposicional, não é só concluir — é concluir bem!






ATUALIZAR Q É CORRIGIR A ESTIMATIVA

a estimativa antiga caminha até à nova experiência.



1. ONDE ESTAMOS?

Temos uma **estimativa antiga** que ainda não considera a nova experiência.



2. O QUE OBSERVAMOS?

Recebemos **nova experiência** (factos) que nos dá mais informação.



3. O QUE FAZEMOS?

Atualizamos Q: **corrigimos a estimativa antiga** para incorporar a nova experiência.



IDEIA-CHAVE

Atualizar Q é mover a nossa estimativa antiga na direção da nova experiência, com um passo ajustado à confiança e à relevância dos factos.

COMO ACONTECE (EM GERAL)

$$Q \text{ nova} = Q \text{ antiga} + \text{ajuste (correção)} \times \text{peso (confiança)}$$



O ajuste aponta na direção do que observámos. O peso decide quanto corrigir.

EXEMPLO PRÁTICO (NAVEGAÇÃO)



A estimativa antiga dizia que estávamos aqui.



Observámos o farol, medimos o rumo e a distância.



Atualizamos: a nova posição é mais consistente com o que foi observado.

PORQUÊ É IMPORTANTE?

- ✓ Torna as decisões mais fiáveis.
- ✓ Reduz erros acumulados.
- ✓ Adapta-nos a novas informações.



LEMBRE-SE:

Não mudamos tudo de uma vez.
Damos pequenos passos bem pensados.



Atualizar Q é aprender com a realidade!



A EQUAÇÃO DO Q-LEARNING, PASSO A PASSO

O Q-Learning é um método de Aprendizagem por Reforço que ensina um agente a tomar melhores ações para obter maiores recompensas ao longo do tempo.

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

1

Valor Q atual

Estimativa atual da qualidade de executar a ação a no estado s .

2

Valor Q atual

O valor existente na tabela Q para o par (s, a) .

3

Taxa de aprendizagem

Controla o quanto o novo conhecimento irá ajustar o valor Q atual.

4

Recompensa imediata

Recompensa recebida após executar a ação a no estado s .

5

Fator de desconto

Controla a importância das recompensas futuras ($0 \leq \gamma < 1$).

6

Melhor valor futuro

Maior valor Q possível no próximo estado s' , entre todas as ações a' .

7

Subtração do valor atual

Remove o valor Q atual para atualizá-lo em direção à nova estimativa (erro temporal).

COMO FUNCIONA, PASSO A PASSO

1

Observe o estado atual (s)



O agente observa o ambiente e identifica o estado em que se encontra.

2

Escolha uma ação (a)



O agente escolhe uma ação com base na sua política (exploração ou exploração).

3

Execute a ação e receba r e s'



O agente executa a ação, recebe uma recompensa r e observa o novo estado s' .

4

Encontre o melhor valor futuro



No novo estado s' , o agente procura o maior valor Q entre todas as ações possíveis.

5

Calcule o alvo (target)



Some a recompensa imediata r com o melhor valor futuro descontado por γ .

6

Atualize o valor Q



Ajuste o valor $Q(s, a)$ atual em direção ao alvo usando a taxa de aprendizagem α .

7

Repita o processo



Repita os passos continuamente até que o agente aprenda a melhor estratégia.

O QUE SIGNIFICA CADA SÍMBOLO

$Q(s, a)$

Valor Q

Estimativa de quão boa é a ação a no estado s .

s, s'

Estado atual e próximo estado

s é o estado atual; s' é o estado após a ação.

a, a'

Ação atual e futura

a é a ação tomada; a' são as ações possíveis em s' .

α

Taxa de aprendizagem

Define o quanto aprendemos com cada experiência.

r

Recompensa imediata

Retorno recebido logo após a ação.

γ

Fator de desconto

Equilibra recompensas imediatas e futuras.

$\max$

Máximo futuro

O melhor valor Q possível no próximo estado s' .



Q ATUAL: O QUE O AGENTE ACREDITAVA

O agente baseia-se no seu conhecimento atual para responder.



FACTOS DISPONÍVEIS



G: O gás está ligado



V: A ventilação está ativa



T: A temperatura é baixa



REGRAS QUE O AGENTE CONHECE

$R_1: G \wedge V \rightarrow P$

$R_2: V \wedge T \rightarrow Q$

$R_3: P \wedge Q \rightarrow E$

$R_4: G \rightarrow R$

$R_5: R \wedge E \rightarrow N$

RACIOCÍNIO DO AGENTE

1 De G e V, aplica R_1 :

P é verdadeiro



2 De V e T, aplica R_2 :

Q é verdadeiro



3 De P e Q, aplica R_3 :

E é verdadeiro



Q ATUAL

Q

VALOR ATUAL

VERDADEIRO

Era isto que o agente acreditava no momento atual.

CONCLUSÃO



Com o conhecimento atual, o agente conclui que Q é verdadeiro.



O valor de Q depende apenas do conhecimento atual do agente.
Com os factos e regras que tem, o agente acreditava que Q era **VERDADEIRO**.





TAXA DE APRENDIZAGEM α




α baixo (próximo de 0) → mudanças pequenas

α alto (próximo de 1) → mudanças grandes

O QUE É A TAXA DE APRENDIZAGEM?

A taxa de aprendizagem (α) controla o tamanho do passo que o algoritmo dá para corrigir seus erros e atualizar seus conhecimentos.



- Passos do algoritmo
- ✗ Solução ideal (objetivo)
- 🎯 Solução encontrada

α BAIXO (PRÓXIMO DE 0)

Mudanças pequenas, aprendizado mais **lento**, porém mais **estável**.



- 🕒 Converte devagar para a solução.
- 🛡️ Menor risco de oscilações.
- ⚓ Bom para problemas sensíveis ou ruidosos.

α ALTO (PRÓXIMO DE 1)

Mudanças grandes, aprendizado mais **rápido**, porém menos **estável**.



- ⚡ Converte rápido (se não oscilar).
- 📉 Maior risco de oscilações ou divergência.
- ⚠️ Bom para problemas simples e bem comportados.

COMO ESCOLHER α ?



Comece com um valor intermediário, como $\alpha = 0,1$.



Observe o comportamento do algoritmo.



Se estiver muito lento, **aumente α gradualmente.**



Se estiver oscilando ou divergindo, **diminua α .**



Ajuste até encontrar o melhor equilíbrio entre velocidade e estabilidade.



EM RESUMO



α é o leme do aprendizado: define o tamanho dos passos em direção à melhor solução.



Muito pequeno: demora para chegar.
Muito grande: pode perder o rumo.
O ideal é encontrar o equilíbrio!



RECOMPENSA IMEDIATA r

resultado observado após a ação marítima.



1. AÇÃO MARÍTIMA

O agente executa uma ação.



Exemplos de ações

- Virar à esquerda
- Aumentar a velocidade
- Manter o rumo
- Tocar buzina
- ...



2. RESULTADO OBSERVADO

O agente observa o que aconteceu no ambiente.



O que pode ser observado?

- Chegou mais perto do objetivo
- Colidiu com um obstáculo
- Saiu da rota
- Nada mudou relevante
- ...



3. RECOMPENSA IMEDIATA r

O agente recebe um valor numérico que indica o quão bom foi o resultado.

+1,0	Excelente resultado (aproximou-se do objetivo)
+0,2	Pequena melhoria
0	Situação inalterada
-0,2	Pequena piora
-1,0	Resultado muito negativo (colisão, perigo, etc.)



A recompensa guia o agente a escolher melhores ações no futuro!



A recompensa imediata r é o **feedback** numérico que o agente recebe logo após cada ação. Ela indica se o resultado observado foi bom ou mau, permitindo aprender e melhorar a navegação.





FATOR DE DESCONTO γ

IMPORTÂNCIA NO FUTURO



O fator de desconto γ ($0 \leq \gamma < 1$) determina o quanto o agente valoriza as recompensas futuras em comparação com as recompensas imediatas.



COMO O γ AFETA AS DECISÕES

γ PRÓXIMO DE 0



- ✓ Foco no presente
- ✓ Recompensas futuras têm pouca importância
- ✓ Decisões mais imediatistas
- ✓ Exemplo: preferir ganho pequeno agora

γ INTERMEDIÁRIO ($0 < \gamma < 1$)



- ✓ Equilíbrio entre presente e futuro
- ✓ Considera recompensas futuras, mas com moderação
- ✓ Decisões ponderadas
- ✓ Exemplo: planejar ganhos maiores com um horizonte razoável

γ PRÓXIMO DE 1



- ✓ Foco no futuro
- ✓ Recompensas futuras têm grande importância
- ✓ Decisões mais visionárias
- ✓ Exemplo: sacrificar ganho atual por grandes recompensas



Valor presente de uma recompensa futura R_{t+k} : $\gamma^k \cdot R_{t+k}$
Quanto maior k (mais distante no tempo), menor o peso da recompensa.

ONDE:

- γ = fator de desconto ($0 \leq \gamma < 1$)
- k = número de passos no futuro





MELHOR VALOR FUTURO

Escolher o maior valor Q disponível no novo estado



1. ESTADO ATUAL



S_t

Agente no estado atual



Exemplo de estado atual do agente

2. AÇÃO



A_t

Ação escolhida pelo agente



Navegar para o norte

3. NOVO ESTADO



S_{t+1}

Novo estado alcançado



Exemplo de novo estado

4. VALORES Q DISPONÍVEIS NO NOVO ESTADO (S_{t+1})

$Q(S_{t+1}, a_1)$



Ir para leste

$Q = 1,5$

$Q(S_{t+1}, a_2)$ ★



Ir para o norte

$Q = 2,7$

$Q(S_{t+1}, a_3)$



Ir para o sul

$Q = 1,8$



máximo = 2,7



O melhor valor futuro é usado na atualização.





EXEMPLO NUMÉRICO — ATUALIZAR Q



Vamos atualizar o valor de $Q(s, a)$ usando a regra de atualização do Q-Learning.



1. FÓRMULA DE ATUALIZAÇÃO

$$Q_{\text{novo}}(s, a) = Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$



2. VALORES DO EXEMPLO



Valor atual:

$$Q(s, a) = 2$$



Taxa de aprendizagem:

$$\alpha = 0.5$$



Recompensa recebida:

$$r = 1$$



Fator de desconto:

$$\gamma = 0.9$$



Máximo próximo estado:

$$\max_{a'} Q(s', a') = 4$$



Estes valores serão usados na fórmula para calcular o novo valor de $Q(s, a)$.



3. SUBSTITUIÇÃO NA FÓRMULA

$$\begin{aligned} Q_{\text{novo}}(s, a) &= Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] \\ &= 2 + 0.5 \left[1 + 0.9 \times 4 - 2 \right] \\ &= 2 + 0.5 \left[1 + 3.6 - 2 \right] \\ &= 2 + 0.5 \left[2.6 \right] \\ &= 2 + 1.3 \end{aligned}$$



Interpretação:

O novo valor de $Q(s, a)$ move-se do valor atual (2) na direção da melhor estimativa futura, ajustado pela taxa de aprendizagem.



4. RESULTADO FINAL

Novo valor atualizado:

$$Q_{\text{novo}}(s, a) = 3.3$$



O valor de $Q(s, a)$ foi atualizado de 2 para 3.3, incorporando a recompensa recebida e a melhor estimativa futura.



RESUMO: A atualização aproxima $Q(s, a)$ da soma da recompensa imediata (r) com o valor futuro descontado ($\gamma \max_{a'} Q(s', a')$), usando a taxa de aprendizagem (α) para controlar o tamanho do ajuste.





ATUALIZAR APENAS UMA CÉLULA DA TABELA Q

Ao receber um novo facto e executar uma ação, atualizamos apenas a célula correspondente.

1. OBSERVAÇÃO

Estado atual (factos verdadeiros):

✓ **G**: verdadeiro

✓ **V**: verdadeiro

Célula a atualizar:

G $\wedge$ **V** $\rightarrow$ **P**

Ação executada:

P: perigo

2. ATUALIZAÇÃO

Regra de atualização (Q-learning):

$$Q_{\text{novo}} = Q_{\text{antigo}} + \alpha [R + \gamma \max(Q_{\text{futuro}}) - Q_{\text{antigo}}]$$

α : taxa de aprendizagem

γ : fator de desconto

R: recompensa recebida

$\max(Q_{\text{futuro}})$: melhor valor futuro estimado



Apenas a célula (**G** $\wedge$ **V** $\rightarrow$ **P**) é recalculada.

Todas as outras permanecem inalteradas.

3. RESULTADO

A célula (**G** $\wedge$ **V** $\rightarrow$ **P**)
é atualizada com
o novo valor.



Aprendizagem
mais precisa
e eficiente!

TABELA Q (EXEMPLO)

Estados \ Ações	P	E	N
G $\wedge$ V $\rightarrow$ P	0,80	0,20	-0,10
G $\wedge$ V $\rightarrow$ E	0,10	0,60	0,00
V $\wedge$ O $\rightarrow$ P	0,30	0,10	-0,20
A $\wedge$ E $\rightarrow$ N	-0,10	0,20	0,70
P $\wedge$ O $\rightarrow$ E	0,00	0,40	0,10
R $\wedge$ S $\rightarrow$ P	0,50	0,10	-0,10
...	...	...	...



Somente esta célula foi alterada.
As restantes não são afetadas.



Confirmação:

Atualizamos apenas a célula da tabela Q correspondente ao estado observado e à ação executada.




REPETIR AO LONGO DE MUITOS EPISÓDIOS

Q valores estabilizam através da experiência.



IDEIA PRINCIPAL

Ao repetir muitas vezes o mesmo tipo de episódio, o agente **aprende** o que funciona melhor.



A experiência repetida **reforça** as melhores escolhas e reduz os erros.



É assim que os valores Q se tornam cada vez mais **estáveis** e **fiáveis**.

EXEMPLO: NAVEGAR NUM CANAL COM CORRENTE

EPISÓDIO 1



Escolhas ainda irregulares

- ✓ Bom
- Razoável
- ✗ Fraco

Q valores ainda instáveis




EPISÓDIO 10



Melhores escolhas mais frequentes

- ✓ Bom
- Razoável
- ✗ Fraco

Q valores a melhorar




EPISÓDIO 50



Escolhas boas na maioria das situações

- ✓ Bom
- Razoável
- ✗ Fraco

Q valores mais estáveis




EPISÓDIO 200+



Escolhas ótimas de forma consistente

- ✓ Bom
- Razoável
- ✗ Fraco

Q valores estabilizados



O QUE ACONTECE COM OS Q VALORES?



Melhoram com a prática e a repetição.



Aproximam-se dos valores ideais.



Tornam-se estáveis e confiáveis, mesmo em novas situações semelhantes.

EM RESUMO



Muitos episódios, melhores decisões, Q valores **estáveis**.



Repetir ao longo de muitos episódios = Aprender com a experiência.

Q valores estabilizam através da experiência.



ε-GREEDY EQUILIBRA EXPLORAÇÃO E APROVEITAMENTO



Na maioria das vezes, aproveitar; ocasionalmente, explorar.



APROVEITAR

escolher a melhor ação conhecida



Usa o que já aprendeu para maximizar a recompensa esperada.

Probabilidade: $1 - \epsilon$



EXPLORAR

experimentar outra ação



Descobre novas informações que podem levar a melhores recompensas no futuro.

Probabilidade: ϵ



COMO FUNCIONA

1

Escolha um valor de ϵ ($0 < \epsilon \leq 1$)

Ex.: $\epsilon = 0,1$ (10%)

2

Em cada decisão:

- com probabilidade $1 - \epsilon$, aproveite (escolha a melhor ação conhecida)
- com probabilidade ϵ , explore (escolha uma outra ação aleatória)



3

Execute a ação, observe a recompensa e atualize o que aprendeu.



4

Repita o processo, equilibrando explorar e aproveitar ao longo do tempo.



Com o tempo, o agente aprende a escolher melhores ações e pode diminuir ϵ para explorar menos e aproveitar mais.





INTERPRETAR ϵ

ϵ alto = mais exploração; ϵ baixo = mais exploração.

ϵ ALTO – MAIS EXPLORAÇÃO

O agente explora mais opções, experimenta e descobre novas rotas.



Seleciona ações aleatórias com maior frequência.



Descobre novos estados e possíveis recompensas.



Útil no início do aprendizado ou em ambientes desconhecidos.

PROBABILIDADE DE AÇÃO

Aleatória (explorar)



ϵ



Melhor conhecida (explorar)



$1 - \epsilon$

INTERPRETAR ϵ



CONTROLE

Ajustamos ϵ ao longo do tempo (decai) para equilibrar exploração e aproveitamento.

ϵ BAIXO – MAIS EXPLORAÇÃO

O agente aproveita o que já aprendeu, escolhendo a melhor rota conhecida.



Seleciona a melhor ação na maioria das vezes.



Maximiza recompensas acumuladas.



Útil quando o agente já conhece bem o ambiente.

PROBABILIDADE DE AÇÃO

Aleatória (explorar)



ϵ



Melhor conhecida (aproveitar)



$1 - \epsilon$



Explorar hoje para encontrar o tesouro amanhã.



Aproveitar o que funciona para chegar ao destino.

EM RESUMO



ϵ alto:
explora mais,
aprende mais.



ϵ baixo:
aproveita mais,
obtem melhores
resultados.



O sucesso está
no equilíbrio entre
exploração e
aproveitamento.



Com o tempo,
diminuimos ϵ para
focar no que
melhor funciona.



Nosso objetivo:
encontrar o melhor
caminho para
maximizar recompensas!

EXTRAIR A POLÍTICA DA TABELA Q

choose maximum Q in each state row.



1 TABELA Q

Contém os valores $Q(s,a)$ para cada estado s e ação a possível.



2 ESCOLHER O MÁXIMO

Para cada linha (estado), escolhe-se a ação com maior valor Q .



3 FORMAR A POLÍTICA

A política π associa a cada estado a ação selecionada.



4 USAR A POLÍTICA

Siga a ação indicada por π em cada estado para agir.

TABELA Q

AÇÕES

ESTADOS

	Navegar (N)	Esperar (E)	Virar à Esquerda (VE)	Virar à Direita (VD)
Céu Limpo	10	4	6	8
Nuvens	7	9	5	6
Chuva	2	6	8	5
Tempestade	-5	-2	-1	0



POLÍTICA EXTRAÍDA π

ESTADO (s)	AÇÃO $\pi(s)$
Céu Limpo	Navegar (N)
Nuvens	Esperar (E)
Chuva	Virar à Esquerda (VE)
Tempestade	Virar à Direita (VD)



IDEIA PRINCIPAL

A política ótima gulosa em relação a Q é obter, em cada estado, a ação que **maximiza** $Q(s, a)$.



★ LEMBRE-SE

- $Q(s, a)$ estima o retorno esperado ao tomar a ação a no estado s .
- Esta extração é válida para políticas determinísticas.



CONCLUSÃO

Para extrair a política da tabela Q , basta escolher a ação com **maior valor Q** em cada linha (estado).



EXERCÍCIO — ATUALIZAR UM VALOR Q

Trabalho em pares • 10 minutos



DADOS DO PROBLEMA

Q $Q = 1$

α $\alpha = 0.4$

r $r = 2$

γ $\gamma = 0.9$

$\max Q$ $\max Q = 3$

REGRA DE ATUALIZAÇÃO DO Q

$$Q_{\text{novo}} = Q + \alpha [r + \gamma \cdot \max Q - Q]$$

Q valor atual do Q

α taxa de aprendizagem ($0 < \alpha \leq 1$)

r recompensa recebida

γ fator de desconto ($0 \leq \gamma < 1$)

$\max Q$ máximo Q possível no próximo estado



PERGUNTA



Qual é o
novo valor de Q
após a atualização?

$Q_{\text{novo}} =$



Mostrem todos os cálculos passo a passo e apresentem o resultado final.





CORREÇÃO – O NOVO VALOR Q É 2,48

Vamos substituir corretamente os novos valores na regra e obter o valor atualizado de Q.

1. A REGRA UTILIZADA

Modus Ponens: A regra prática da dedução



A REGRA MATEMÁTICA:

$$Q = 1 + 0.4[2 + 0.9 \times P - 1]$$

ONDE:

- ▶ **P** = valor numérico do fato observado.
- ▶ **Q** = novo valor concluído pela regra.

2. NOVOS VALORES DISPONÍVEIS



P (valor atualizado)

3



Outros parâmetros

Constantes: 1, 0.4, 2 e 0.9

3. SUBSTITUIÇÃO CORRETA NA FÓRMULA

$$Q = 1 + 0.4[2 + 0.9 \times 3 - 1]$$

$$0.9 \times 3 = 2.7$$

$$2 + 2.7 - 1 = 3.7$$

$$0.4 \times 3.7 = 1.48$$

$$1 + 1.48 = \mathbf{2.48}$$

CONCLUSÃO:

O NOVO VALOR DE **Q** É
2,48



DICA DO NAVEGANTE

Substitua sempre com atenção e respeite a ordem das operações! Pequenos detalhes fazem uma grande diferença na resposta.





SÍNTESE — A EXPERIÊNCIA CONSTRÓI A POLÍTICA


A experiência gera perguntas, a exploração encontra respostas e a política aprendida orienta novas ações.



1 EXPERIÊNCIA

AGIMOS E OBSERVAMOS

Realizamos ações e observamos os resultados.




Toda ação gera informação valiosa sobre o que acontece.

2 PERGUNTAS E ATUALIZAÇÕES

TRANSFORMAMOS EM PERGUNTAS

Analisamos o que aprendemos e formulamos perguntas.



Atualizamos conhecimentos e redefinimos o rumo.

3 EXPLORAÇÃO

EXPLORAMOS E TESTAMOS

Procuramos respostas, testamos ideias e comparamos resultados.




Experimentamos caminhos para encontrar o que resulta.

4 POLÍTICA APRENDIDA

CONSTRUÍMOS POLÍTICA

Transformamos o que aprendemos em orientação para o futuro.



A política aprendida orienta decisões e futuras ações.



EXPERIÊNCIA → PERGUNTAS E ATUALIZAÇÕES → EXPLORAÇÃO → POLÍTICA APRENDIDA



Aprendemos com o passado



Entendemos o presente



Preparamos o futuro

