


Decisão Sequencial e Aprendizagem por Reforço

MDP, Value Iteration e Q-Learning

Escolher ações pelo efeito nas recompensas futuras

O que vamos aprender

- 1 Modelar estados, ações, transições e recompensas
- 2 Interpretar políticas e funções de valor
- 3 Resolver um MDP com Value Iteration
- 4 Aprender por experiência com Q-Learning



$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

Retorno descontado, $0 \leq \gamma < 1$



Modelar

Descrever o problema como um MDP



Planejar

Calcular uma política com um modelo




Aprender

Melhorar decisões a partir de transições observadas

Decisões com consequências futuras

Um exemplo simples de como as decisões atuais afetam as oportunidades futuras.

1. Diagrama de decisão (dois caminhos)



2. Cálculo dos retornos ($\gamma = 0,9$)

- **Sair:** $G_0 = 1$
- **Avançar:** $G_0 = 0 + 0,9 \times 4 = 3,6$

A melhor recompensa imediata pode conduzir a um retorno inferior.

3. Conceitos principais

- **Decisão sequencial:** a ação altera o estado e as oportunidades seguintes.
- **Objetivo:** maximizar o retorno esperado.
- **Horizonte:** número de decisões consideradas.

4. Comparação para diferentes γ

γ	sair	avançar	escolha
0	1	0	sair
0,2	1	0,8	sair
0,9	1	3,6	avançar

Exemplo didático. Recompensas recebidas nas transições.

Interação entre agente e ambiente

Estado s_t :

informação usada para decidir.

Ação a_t :

escolha do agente.


Recompensa r_{t+1} :

sinal numérico após a ação.


Política π :

regra de escolha das ações.

$$a_t \sim \pi(a \mid s_t)$$



Robô de navegação



Estado: posição e bateria.

Ação: mover ou carregar.

Recompensa: progresso, chegada e custos.

Evolução no tempo (interação sequencial)



O agente procura retorno acumulado. A recompensa de um passo pode ser negativa.

Processo de Decisão de Markov

Definição


Um Processo de Decisão de Markov (MDP) é definido por

$$MDP = (S, A, P, R, \gamma)$$

Símbolo	Significado
S	conjunto de estados
$A(s)$	ações disponíveis em s
$P(s' s, a)$	probabilidade de transição
$R(s, a, s')$	recompensa esperada nessa transição
γ	fator de desconto, $0 \leq \gamma < 1$

Transições e probabilidades

Ao executar a ação a no estado s , o agente transita para um dos possíveis sucessores de acordo com uma distribuição de probabilidade.



$$\sum_{s'} P(s'|s, a) = 1$$

Modelo determinístico:

um sucessor tem probabilidade 1.

Modelo estocástico:

uma ação pode ter vários sucessores.


Nesta aula: MDP finito, recompensas limitadas e estado terminal T com $V(T) = 0$. A recompensa de chegada a T pertence à transição.

Estado e propriedade de Markov

$$P(s_{t+1} \mid s_0, a_0, \dots, s_t, a_t) = P(s_{t+1} \mid s_t, a_t)$$


Dado o estado atual e a ação, o histórico não acrescenta informação sobre o próximo estado.

Estado incompleto: posição



Na mesma posição, a autonomia pode alterar o resultado de uma ação.

Estado mais informativo: posição e bateria



Uma boa representação inclui as variáveis relevantes para prever transições e recompensas.

Observação: o que os sensores medem

O agente não tem acesso direto ao estado e observa um sinal o_t dos sensores.

Exemplo:

$$o_t = [d_{frente}, d_{esquerda}, d_{direita}]$$

A observação pode ser ruidosa ou incompleta, fornecendo apenas informação parcial sobre o estado.

Estado: informação suficiente para o modelo

Um estado s_t é uma representação que torna o processo de decisão markoviano: a distribuição do próximo estado e da recompensa depende apenas do estado atual e da ação.

$$P(s_{t+1}, r_{t+1} \mid s_0, a_0, \dots, s_t, a_t) = P(s_{t+1}, r_{t+1} \mid s_t, a_t)$$

Um bom estado inclui as variáveis relevantes para prever transições e recompensas.

Parcialmente observável: pode exigir memória ou crenças sobre o estado

Quando as observações não determinam unicamente o estado, o problema é parcialmente observável.


Estratégias comuns:

- Manter um histórico recente de observações e ações.
- Usar uma crença (distribuição de probabilidade) sobre o estado.
- Tratar o problema como um POMDP.

A propriedade de Markov é uma hipótese do modelo que deve ser justificada.

Um MDP para acompanhar toda a aula

1. Diagrama do MDP



2. Tabela de transições

Estado	Ação	Sucessor	P	R
A	sair	T	1	1
A	avançar	B	1	0
B	terminar	T	1	4
B	voltar	A	1	-1

3. Elementos principais

$$S = \{A, B, T\}$$
$$\gamma = 0,9$$
$$V(T) = 0$$

4. Notas importantes

- Não existem ações após terminar.
- As recompensas são recebidas nas transições.
- Exemplo determinístico para tornar os cálculos transparentes.

5. Ideia central

Mesmo com transições certas, é necessário avaliar consequências futuras.

Recompensa, retorno e desconto

Definição do retorno descontado

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

Forma equivalente

$$G_t = r_{t+1} + \gamma G_{t+1}$$

Definições


r : recompensa de um passo

G : soma descontada das recompensas futuras

γ : peso das consequências distantes

Exemplo de trajetória

Consideremos a trajetória $A \rightarrow \text{avançar} \rightarrow B \rightarrow \text{terminar} \rightarrow T$, com recompensas 0 e 4, e $\gamma = 0,9$.



$$G_0 = 0 + 0,9 \times 4 = 3,6$$

$$G_1 = 4$$

Peso das recompensas futuras

γ	peso após 1 passo	peso após 5 passos
0	0	0
0,5	0,5	0,03125
0,9	0,9	0,59049

γ próximo de 1 dá mais peso ao futuro. $\gamma = 0$ considera apenas a recompensa imediata.

Em tarefas episódicas adequadas, $\gamma = 1$ pode ser usado, mas fica fora das garantias descontadas aqui apresentadas.

Política: como escolher uma ação

Política determinística

$$a = \pi(s)$$

Definição: Uma política especifica o comportamento em cada estado.

Estado s	Ação $a = \pi(s)$
A	avançar
B	terminar

Política estocástica

$$\pi(a|s) = P(a_t = a \mid s_t = s)$$

Definição: Uma política especifica o comportamento em cada estado.

Estado s	Ação a	$\pi(a s)$
A	avançar	0,8
A	sair	0,2

$$\sum_a \pi(a|s) = 1$$

Comparação de políticas (exemplo)

No MDP do exemplo, com $\gamma = 0,9$:

- $\pi_1(A) = \text{sair}$: retorno em A = 1
- $\pi_2(A) = \text{avançar}$, $\pi_2(B) = \text{terminar}$: retorno em A = 3,6

A política estocástica com 0,8 avançar e 0,2 sair, terminando sempre em B, tem retorno esperado

$$0,8 \times 3,6 + 0,2 \times 1 = 3,08$$

Uma política escolhe ações. A função de valor avalia as consequências dessa escolha.

Funções de valor V e Q

Função de valor de estados V

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid s_t = s]$$

Valor esperado da soma de recompensas (retorno) ao **começar em s e seguir π** .

Função de valor de ações Q


$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid s_t = s, a_t = a]$$

Valor esperado da soma de recompensas (retorno) ao **executar a em s e depois seguir π** .

Relação entre V e Q

$$V^{\pi}(s) = \sum_a \pi(a \mid s) Q^{\pi}(s, a)$$

Exemplo: MDP determinístico



Cálculos para a política $\pi(A) = \text{avançar}$, $\pi(B) = \text{terminar}$

Quantidade	Valor
$Q^{\pi}(A, \text{sair})$	1
$Q^{\pi}(A, \text{avançar})$	$0 + 0,9 \times 4 = 3,6$
$V^{\pi}(A)$	3,6
$V^{\pi}(B)$	4
$V^{\pi}(T)$	0

Valor de um estado depende da política. Q permite comparar ações no mesmo estado.

Equações de Bellman

Avaliar uma política

$$V^\pi(s) = \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^\pi(s')]$$

$V^\pi(s)$: valor do estado s sob a política π .

$\pi(a|s)$: probabilidade de escolher a ação a no estado s .

$P(s'|s, a)$: probabilidade de transição para o estado s' .

$R(s, a, s')$: recompensa imediata.

γ : fator de desconto.

$V^\pi(s')$: valor do estado seguinte s' .

Procurar a melhor política

$$V^*(s) = \max_a \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^*(s')]$$

$V^*(s)$: valor ótimo do estado s .

$\max_a$: escolhe a ação a que maximiza o valor esperado.

$P(s'|s, a)$: probabilidade de transição para o estado s' .

$R(s, a, s')$: recompensa imediata.

γ : fator de desconto.

$V^*(s')$: valor ótimo do estado seguinte s' .

Soma: média dos resultados possíveis

A soma pondera os resultados possíveis pelas suas probabilidades.

$$\sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V(s')]$$

Máximo: melhor ação disponível

O operador máximo escolhe a ação com maior valor.

$$\max_a (\dots)$$

Exemplo estocástico independente

Considere uma ação a no estado s com dois resultados possíveis:

$P(B s, a) = 0,8$	$V(B) = 4$
$P(T s, a) = 0,2$	$V(T) = 0$
$R(s, a, B) = 0$	$\gamma = 0,9$

O valor da ação é:

$$Q(s, a) = 0,8 \times (0 + 0,9 \times 4) + 0,2 \times 0 = 2,88$$

Value Iteration: algoritmo

Algoritmo (versão síncrona)

- 1: **Inicializar** $V(s) = 0$ para todos os estados
- 2: **repetir**
- 3: **para cada** estado não terminal s :
- 4: $V_{novo}(s) \leftarrow \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V(s')]$
- 5: $V_{novo}(T) \leftarrow 0$
- 6: $\Delta \leftarrow \max_s |V_{novo}(s) - V(s)|$
- 7: $V \leftarrow V_{novo}$
- 8: **até** $\Delta < \theta$
- 9: **devolver** V

Equação de atualização

$$V_{k+1}(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V_k(s')]$$

Explicações

- 1 Modelo P e R conhecido
- 2 Cada varrimento usa os valores do varrimento anterior
- 3 $\theta > 0$ define a tolerância de paragem
- 4 Extrair a política a partir do valor final

Para MDPs finitos descontados, o operador de Bellman é uma contração.

Value Iteration: cálculo passo a passo

MDP determinístico do exemplo ($\gamma = 0,9$).

Recompensas: sair = 1, avançar = 0, terminar = 4, voltar = -1.

Valores por iteração (varrimentos k)

k	$V_k(A)$	$V_k(B)$	$V_k(T)$
0	0	0	0
1	1	4	0
2	3,6	4	0
3	3,6	4	0

Os índices k contam varrimentos do algoritmo, não passos do agente.

Actualizações síncronas (Bellman)

Varrimento $k = 1$ (a partir de V_0)

$$V_1(A) = \max\{1, 0 + 0,9 \times 0\} = 1$$

$$V_1(B) = \max\{4, -1 + 0,9 \times 0\} = 4$$

Varrimento $k = 2$ (a partir de V_1)


$$V_2(A) = \max\{1, 0 + 0,9 \times 4\} = 3,6$$

$$V_2(B) = \max\{4, -1 + 0,9 \times 1\} = 4$$

Varrimento $k = 3$ (a partir de V_2)

$$V_3(B) = \max\{4, -1 + 0,9 \times 3,6\} = 4$$

MDP (recompensas nas transições)



Resultado:

$$V^*(A) = 3,6, \quad V^*(B) = 4, \quad V^*(T) = 0$$

Política ótima e critério de paragem

Política ótima

$$\pi^*(s) \in \operatorname{argmax}_a \sum_{s'} P(s' \mid s, a) [R(s, a, s') + \gamma V^*(s')]$$

$\pi^*(s)$: ação ótima no estado s .
 $P(s' \mid s, a)$: probabilidade de transição.
 $R(s, a, s')$: recompensa imediata.
 $V^*(s')$: valor ótimo do estado seguinte.
 γ : fator de desconto.

Exemplo de MDP

Estado	valores das ações	escolha
A	sair: 1; avançar: 3,6	avançar
B	terminar: 4; voltar: 2,24	terminar

$$Q^*(B, voltar) = -1 + 0,9 \times 3,6 = 2,24$$

Convergência

- B : operador de Bellman ótimo.
- B é uma contração no máximo:

$$\|BV - BW\|_\infty \leq \gamma \|V - W\|_\infty$$

V, W : funções de valor.
 $\|\cdot\|_\infty$: norma do máximo.
 $0 \leq \gamma < 1$: fator de desconto.

Resíduo e erro de valor

- **Resíduo:**

$$r = \|BV - V\|_\infty$$

- Implica o limite do erro:

$$\|V - V^*\|_\infty \leq \frac{r}{1 - \gamma}$$

- **Exemplo:**

$$\gamma = 0,9 \text{ e } r \leq 0,01 \text{ garantem erro de valor } \leq 0,1.$$

Esta desigualdade limita o erro dos valores. A qualidade da política requer uma análise própria.

Planeamento e aprendizagem por reforço

Planeamento com modelo

P, R → **Value Iteration** → V, π

- Calcula consequências **sem executar todas as ações**.
- Exige **modelo** das **transições** e **recompensas**.


Aprendizagem pela experiência

interação → (s, a, r, s') → **Qlearning** → Q, π

- Atualiza estimativas com **transições observadas**.
- Q-Learning **dispensa um modelo explícito** de P e R .

Model-based RL

aprende um modelo e usa-o para planear.



RL é mais amplo do que Q-Learning.

Model-free RL


aprende valores ou uma política sem construir esse modelo.

Experiência, episódios e sinal de treino

Transição: uma observação (s, a, r, s') .

Episódio: sequência até um estado terminal.

Crédito temporal: relacionar ações anteriores com recompensas posteriores.



s	a	r	s'	terminal
A	avançar	0	B	não
B	terminar	4	T	sim

A **recompensa tardia** exige propagar informação.

O **ambiente** fornece recompensas, sem indicar necessariamente a ação correta.

Numa transição terminal, o valor futuro usado no alvo é zero.

Aprendizagem supervisionada: exemplos com respostas-alvo.

Reinforcement Learning: decisões, consequências e retorno.

Explorar e aproveitar o conhecimento

Exploration e exploitation

Definições

Explorar: experimentar ações para obter informação.

Aproveitar: escolher a melhor ação segundo Q .

Algoritmo ϵ -greedy

- **Com probabilidade ϵ :** escolher uniformemente uma ação.
- **Com probabilidade $1 - \epsilon$:** escolher uma ação com maior Q .

Exemplo com duas ações

$$Q(\text{avançar}) = 3, Q(\text{sair}) = 1, \epsilon = 0,2:$$

$$P(\text{avançar}) = 0,8 + 0,2/2 = 0,9$$

$$P(\text{sair}) = 0,2/2 = 0,1$$

Probabilidade das ações

90% avançar	10% sair
----------------	-------------

Considerações importantes

- ϵ alto aumenta a exploração.
- Reduzir ϵ demasiado cedo pode impedir a descoberta de boas ações.
- Empates no máximo podem ser resolvidos aleatoriamente.

Nota: Nesta convenção, a escolha aleatória inclui também a ação gulosa.

Q-Learning: atualização por diferença temporal

Fórmula de atualização

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

Alvo da atualização

$$y = r + \gamma \max_{a'} Q(s', a')$$

Erro de diferença temporal

$$\delta = y - Q(s, a)$$

Tabela de símbolos

α	taxa de aprendizagem
γ	desconto
r	recompensa observada
$\max Q$	melhor valor estimado no próximo estado

Conceitos principais

- Atualiza apenas o par (s, a) observado
- Usa uma amostra da transição
- **Bootstrapping:** o alvo usa outra estimativa
- **Off-policy:** o alvo é guloso, mesmo quando a ação de comportamento explora

Se s' é terminal


$y = r$ e não se calcula max sobre ações inexistentes.

Q-Learning: atualização numérica

Transição não terminal $A \rightarrow B$

Dados de entrada:

$Q(A, \text{avançar}) = 1$
 $Q(B, \text{terminar}) = 4$
 $Q(B, \text{voltar}) = 2$
 $\alpha = 0,5$
 $\gamma = 0,9$
 $r = 0$




Cálculo da atualização:

- 1 Calcular o alvo (target) y :
 $y = 0 + 0,9 \times \max(4, 2) = 3,6$
- 2 Calcular o erro temporal δ :
 $\delta = 3,6 - 1 = 2,6$
- 3 Atualizar o valor Q :
 $Q_{\text{novo}}(A, \text{avançar}) = 1 + 0,5 \times 2,6 = 2,3$

Transição terminal $B \rightarrow T$

Dados de entrada:

$Q(B, \text{terminar}) = 2$
 $\alpha = 0,5$
 $r = 4$



Cálculo da atualização:

- 1 Calcular o alvo (target) y :
 $y = 4$
- 2 Calcular o erro temporal δ :
 $\delta = 4 - 2 = 2$
- 3 Atualizar o valor Q :
 $Q_{\text{novo}}(B, \text{terminar}) = 2 + 0,5 \times 2 = 3$

As duas atualizações são exemplos independentes.

Uma atualização não representa convergência.

Valores não visitados mantêm-se inalterados.

Q-Learning tabular: pseudocódigo

```
Inicializar  $Q(s, a) = 0$  para pares válidos
para cada episódio:
  observar estado inicial  $s$ 
  enquanto  $s$  não for terminal:
    escolher  $a$  por  $\epsilon$ -greedy sobre  $Q(s, \cdot)$ 
    executar  $a$  e observar  $r, s'$ , terminal
    se terminal:  $y \leftarrow r$ 
    senão:  $y \leftarrow r + \gamma \max_{a'} Q(s', a')$ 
     $Q(s, a) \leftarrow Q(s, a) + \alpha[y - Q(s, a)]$ 
     $s \leftarrow s'$ 
devolver  $Q$ 
```

Política final:

$$\pi(s) \in \operatorname{argmax}_a Q(s, a)$$

Guardar uma entrada por par estado-ação válido

Usar sementes distintas para avaliar variabilidade

Separar treino de avaliação

O máximo usa apenas ações válidas no próximo estado. Um limite artificial de duração não equivale necessariamente a um terminal do MDP.

Parâmetros e condições de convergência

Parâmetros e os seus efeitos

Parâmetro	efeito	cuidado
α	peso da nova observação	valor elevado aumenta variabilidade
γ	peso do futuro	valor próximo de 1 exige propagação mais longa
ϵ	frequência de exploração	redução precoce pode limitar cobertura

Convergência tabular para Q^*

Condições:

- MDP finito e estacionário, recompensas limitadas, $0 \leq \gamma < 1$.
- Todos os pares válidos (s, a) visitados infinitas vezes.
- Por par: $\sum \alpha_t(s, a) = \infty$ e $\sum_t \alpha_t(s, a)^2 < \infty$.

Exemplo:

$$\alpha_n = \frac{1}{n}, \text{ com } n \text{ a contagem de visitas ao par.}$$

Considerações importantes

- α constante é útil em exemplos e adaptação, mas não satisfaz estas condições assintóticas.
- As garantias tabulares não se transferem automaticamente para redes neurais.

Value Iteration e Q-Learning

Critério	Value Iteration	QLearning
Informação	modelo P, R	transições observadas
Atualização	esperança sobre sucessores	maximização futura numa amostra
Valores	V ou Q	Q
Exploração do ambiente	não é necessária para calcular	necessária para aprender
Limitação	custo e qualidade do modelo	número e cobertura das experiências

Avaliação de uma política

- Medir retorno médio em episódios independentes
- Reportar dispersão, taxa de sucesso e número de interações
- Usar várias sementes e o mesmo orçamento de treino
- Na avaliação gulosa, $\epsilon = 0$, sem novas atualizações

Comparar políticas exige a mesma definição de recompensa, desconto e condições iniciais.

Exercício: calcular e explicar uma decisão

Estado do MDP do exemplo

Estado	Ação	Próximo estado	Recompensa
A	sair	T	1
A	avançar	B	0
B	terminar	T	4
B	voltar	A	-1

Transições determinísticas, $\gamma = 0,9$, $V_0 = 0$.

Questões

- 1

Calcule V_1 e V_2 .
- 2

Escolha a política gulosa em V_2 .
- 3

Atualize $Q(A, \text{avançar})$, com Q antigo = 1, $\max Q(B, \cdot) = 4$, $\alpha = 0,5$ e $r = 0$.
- 4

Explique porque a recompensa imediata pode induzir uma escolha inferior.

Conferência dos resultados

V_1	$V_1(A) = 1, V_1(B) = 4$
V_2	$V_2(A) = 3,6, V_2(B) = 4$
Política gulosa em V_2	$\pi(A) = \text{avançar}, \pi(B) = \text{terminar}$
Atualização de Q	$Q_{\text{novo}}(A, \text{avançar}) = 2,3$
Explicação	Sair dá 1; avançar e terminar dá 3,6.

MDP descreve o problema. Value Iteration planeia com um modelo. Q-Learning aprende valores de ações com experiência.